

Lvy

AGI实习生 | 一周到岗 | 长期实习
20岁 | 女 | GitHub: lvy010
Email: lvyovo010@163.com



学习经历

2023-09 ~ 2027-06

羽丘女子学园

计算机

个人文档

喜欢解决问题和看各种设计 | 快速学习并沉淀系统文档 | 自己理解后分享

- 作品集: <https://b23.tv/adNU4UH>
- 我的262个github仓库整理 — https://github.com/lvy010/X-Plore/blob/main/repo/github_repos_cn.md
- 140w+浏览的个人技术专栏 — <https://lvyovo-wiki.tech/share>
- 我的项目整合 — <https://lvyovo-wiki.tech/projects>
- 如何科学的8个月写2000题Leetcode — <https://github.com/lvy010/Algo-Atlas>
- 一千多篇文章整合 — <https://github.com/lvy010/X-Plore>
- 500h播客纪念&分享 — <https://lvyovo-wiki.tech/blog/podcast>
- 一个月回复1k条自媒体消息 — <https://xhslink.com/m/A0RmObjbu2e>
- 2025计算机学习分享 — <https://lvyovo-wiki.tech/blog/25sum>
- 2024 C++自学分享 (C 语言、数据结构、算法、C++、Linux、Mysql、Redis 文档学习、Docker 云原生、Git、Qt) — <https://lvynote.blog.csdn.net/article/details/145308270>

团队项目

2026-04 ~ 2026-05

vLLM - Kernel

推理优化

Fuse dual RMSNorm + residual + scalar in Gemma4 MoE layers

- Gemma4 MoE 层后半段 3×RMSNorm + add + residual + scalar 拆为 5 次 kernel launch，存在大量冗余 HBM 带宽消耗
- 设计并实现单个 Triton fused kernel，将上述操作合并，全程 fp32 寄存器计算，最终一次 cast bf16，消除 3次中间截断，精度优于 unfused 路径
- kernel 级加速 ~9.5× (254μs → 26μs) ，Gemma4-26B-A4B 18 个 MoE 层 decode 每 token 节省约 4ms
- 三天快速上手发现问题，尝试解决并完成测试记录 <http://xhslink.com/o/1jhV61MlNNc>

技术栈: Triton、CUDA Kernel Fusion、RMSNorm、MoE、PyTorch、fp32/bf16混合精度

2026-03 ~ 2026-04

Xiaohongshu - Hackathon

AGI开发

Jarvis — Proactive Multimodal Agent

- 设计并实现主动式 AI 感知系统，让 AI 从"被动问答"进化为"主动感知现实并自主行动"
- 采用 Input / Brain / Output 三层架构，Reactor 调用同时完成多模态感知融合、意图推理与行动决策，低延迟
- 接入摄像头 (OpenCV)、桌面截屏、讯飞 ASR 语音、浏览器历史四路信号，构建统一上下文流
- 设计反馈闭环机制，通过 preferences.json 持续记录用户行为，驱动偏好学习系统自动进化用户画像

技术栈: LLM Agent、Multimodal、Docker、OpenCV、ASR、FastAPI、WebSocket、React、TypeScript

2025-12 ~ 2026-03

中国科学院软件研究所

Rust开发

参与 Web3 Infra 分布式构建平台 的 Orion 构建服务后端开发，进行 Buck2 构建系统的日志管理与 API 重构。

- 设计并实现多目标日志隔离架构，新增 targets 数据模型及完整生命周期管理
- 将分散的日志数据模型统一迁移至 api-model crate，标准化跨模块 API 边界
- 扩展 REST API，支持按构建 ID 查询历史日志及任务目标状态汇总，并通过 utoipa 自动生成 Swagger 文档。

技术栈: Axum、Sea-ORM、PostgreSQL、RESTful API、utoipa/OpenAPI、Buck2、模块化架构重构

参与 **XiaoMi Vela** 嵌入式操作系统的应用开发

- 对嵌入式资源受限环境进行内存与渲染性能调优，优化 LVGL 界面刷新效率，降低系统资源占用
- 基于 LVGL 图形库独立完成**音乐播放器**项目的开发与集成
- 负责项目从零搭建、编译路径配置与修复、代码格式规范化
- 同步跟进组内版本更新和维护中英技术文档

技术栈：LVGL图形学、NuttX/Vela RTOS、嵌入式开发、CMake

实验教程

2024-09 ~ 2026-02

AI Exploration

作者

含微信 AI Bot、AI 图像故事生成、CUDA/CUTLASS 高性能矩阵运算、E3NN 等变神经网络、Pyro 概率编程、RAG 评估等方向。

技术栈：Python、PyTorch、CUDA、CUTLASS、E3NN、Pyro、OpenAI API、Stable Diffusion

2023-09 ~ 2024-09

Linux Lab

作者

操作系统学习与实验聚合仓库，含 CSAPP/OSTEP 笔记与配套代码（虚拟化、并发、持久化）、Linux 内核学习记录及系统编程实践。

技术栈：C/C++、Shell、Makefile、CMake、Linux 内核、系统编程

个人项目

2026-02 ~ 2026-03

NanoAIOS

Rust开发

面向 Agent 时代的极简 AIOS 内核实现，定位为"AIOS 的 Linux"。采用 Kernel/Runtime/Provider 三层分离架构，提供推理入口、Session 记忆管理、多 Provider 抽象等系统级 AI 能力。

技术栈：Cargo、CLI、Session 内存管理、多 Provider 抽象、HTTP 服务

2026-01 ~ 2026-02

Next AI Slide

JS开发

AI 驱动的 Sliddev Markdown 生成器，用户输入自然语言即可自动生成演示文稿，支持复制与下载。基于 Next.js 构建，集成 OpenAI API 实现智能内容生成的**多模态Agent**

技术栈：Next.js、TypeScript、React、OpenAI API、Sliddev、Tailwind CSS

2025-12 ~ 2026-01

GitHub Agent

Python开发

自主式 GitHub 研究智能体，可对任意 GitHub 用户或仓库进行结构化分析。支持任务自动分解、数据采集、完整性自校验，并输出结论与可执行建议，具备多轮对话上下文保持能力。

技术栈：OpenAI API、REST API、Typer、Rich、Bun、React、Ink、Tavily API、多智能体架构

2025-02 ~ 2025-03

分布式 RPC 服务框架

C++开发

设计并实现轻量级 RPC 框架，采用三层架构，通过 LV 协议解决消息边界问题，支持 JSON 序列化实现跨语言通信，提供服务动态注册、发现及负载均衡能力。

技术栈：Jsoncpp、Muduo、多线程编程、TCP 网络通信、发布订阅模式、分布式协调

2024-10 ~ 2024-11

Boost 搜索引擎

C++开发

基于 Boost 在线文档的站内搜索引擎，为用户提供快速查询服务。

技术栈：STL、准标准库 Boost、Jsoncpp、cppjieba、cpp-httpplib